

# Capítulo 5

## Generación de variables aleatorias discretas

Existen distintos métodos para generar variables aleatorias discretas a partir de un generador de números aleatorios. En particular veremos los siguientes:

1. Método de la **Transformada Inversa**.
2. Método de **aceptación y rechazo**, o simplemente **método de rechazo**.

Cada uno de estos métodos puede a su vez ser mejorado u optimizado según cuál es la variable aleatoria en particular que se desea simular. En todos los casos se asume la existencia de un buen generador de números aleatorios, es decir, de valores de una variable aleatoria uniforme en  $(0, 1)$ .

### 5.1. Método de la transformada inversa

Consideremos una variable aleatoria discreta  $X$ , con función de probabilidad de masa dada por:

$$P(X = x_j) = p_j, \quad j = 0, 1, \dots, \quad 0 < p_j < 1,$$

donde los valores  $\{x_n\}$  de la variable están ordenados en forma creciente. Esto es, si  $i < j$  entonces  $x_i < x_j$ .

La función de distribución acumulada de  $X$ ,  $F_X$ , satisface:

$$F_X(x) = \begin{cases} 0 & x < x_0 \\ p_0 & x_0 \leq x < x_1 \\ p_0 + p_1 & x_1 \leq x < x_2 \\ \vdots & \vdots \\ p_0 + p_1 + \cdots + p_{n-1} & x_{n-1} \leq x < x_n \\ \dots & \dots \end{cases}.$$

El método de la transformada inversa lleva este nombre porque se basa en la inversa de la función de distribución acumulada  $F_X$ . Es claro que si  $X$  es una variable aleatoria discreta, entonces  $F_X$  no es inyectiva y por lo tanto tampoco es inversible, pero sí establece una correspondencia biunívoca entre ciertos subintervalos de  $[0, 1)$  y los valores de la variable aleatoria  $X$  a través de la función de distribución  $F_X$ . La correspondencia es la siguiente:

$$\begin{aligned} x_0 &\longrightarrow I_0 = [0, p_0) \\ x_1 &\longrightarrow I_1 = [p_0, p_0 + p_1) \\ x_2 &\longrightarrow I_2 = [p_0 + p_1, p_0 + p_1 + p_2) \\ \dots &\dots \end{aligned}$$

Notemos que estos subintervalos del intervalo  $[0, 1)$  son disjuntos, su unión es el intervalo  $[0, 1)$  y la longitud de  $I_j$  es  $p_j$ . Por otro lado, si consideramos una variable aleatoria con distribución uniforme  $U \sim U(0, 1)$ , entonces la probabilidad que  $U$  tome valores en el intervalo  $I_j$  es  $p_j$ :

$$P(p_0 + \cdots + p_{j-1} \leq U < p_0 + p_1 + p_2 + \cdots + p_j) = p_j.$$

El método de la transformada inversa propone generar valores de  $X$  generando una variable aleatoria uniforme, y según a qué intervalo pertenece  $U$  es el valor de  $X$  que se genera. Es decir: si  $U \in [0, p_0)$ , se genera  $x_0$ . Si  $U \in [p_0, p_0 + p_1)$ , se genera  $x_1$ , y así siguiendo.

El algoritmo general sería como el siguiente:

---

```
# x: vector de valores posibles de X
# p: vector de probabilidades
def discretaX(p, x):
    U = random()
    i, F = 0, p[0]
    while U >= F:
        i, F = i + 1, F + p[i]
    return x[i]
```

---

**Ejemplo 5.1.** Si consideramos la variable aleatoria  $X$  que toma valores en el conjunto  $\{1, 2, 3, 4\}$ , con las probabilidades:

$$p_1 = 0.20, \quad p_2 = 0.15, \quad p_3 = 0.25, \quad p_4 = 0.40,$$

el algoritmo de transformada inversa para generar valores de  $X$  es como sigue:

---

```
def generaX1():
    U = random()
    if U < 0.20: return 1
    elif U < 0.35: return 2
    elif U < 0.60: return 3
    else: return 4
```

---

Una primera mejora que puede hacerse a este algoritmo, y que en general vale para cualquier generador de variables aleatorias discretas, es ordenar las probabilidades de mayor a menor manteniendo la correspondencia entre estas probabilidades y los valores a generar. Esto reduce el número de comparaciones, puesto que cada condicional ( $U < F_X$ ) es más probable que sea aceptado cuanto mayor sea  $F_X$ . Así, en el ejemplo anterior, las probabilidades se ordenarían de la siguiente forma:

$$p_4 = 0.40, \quad p_3 = 0.25, \quad p_1 = 0.20, \quad p_2 = 0.15,$$

y el algoritmo modificado sería como sigue:

---

```
def generaX2():
    U = random()
    if U < 0.40: return 4
    elif U < 0.65: return 3
    elif U < 0.85: return 1
    else: return 2
```

---

Notemos que el número esperado de comparaciones en el primer caso es

$$1 \cdot 0.20 + 2 \cdot 0.15 + 3 \cdot 0.65 = 2.45$$

mientras que en el segundo es:

$$1 \cdot 0.40 + 2 \cdot 0.25 + 3 \cdot 0.35 = 1.95$$

Dado que  $2.45/1.95 \simeq 1.26$  se tiene que el primer algoritmo (`generaX1`) tarda en promedio un 26 % más de tiempo que el segundo (`generaX2`) en lo que se refiere al tiempo en comparaciones.

**5.1.1. Generación de una variable aleatoria uniforme discreta**

Si  $X$  es una variable con distribución uniforme discreta en  $\{1, \dots, n\}$  entonces  $p_1 = p_2 = \dots = p_n = \frac{1}{n}$ . La aplicación del método de la transformada inversa conduce al siguiente algoritmo:

---

```
def udiscreta(n):
    U = random()
    x = 1; F = 1/n
    while U >= F:
        F += 1 / n
        x += 1
    return x
```

---

Este algoritmo recorre los subintervalos de longitud  $1/n$  hasta encontrar aquel donde se encuentra el valor de  $U$ . El algoritmo arrojará el valor  $X = j$  si y sólo si  $U$  cae en el  $j$ -ésimo subintervalo:

$$X = j \quad \text{si y sólo si} \quad \frac{j-1}{n} \leq U < \frac{j}{n}$$

Ahora bien,

$$U \in \left[ \frac{j-1}{n}, \frac{j}{n} \right) \quad \text{si y sólo si} \quad nU \in [j-1, j) \quad \text{si y sólo si} \quad [nU] + 1 = j,$$

donde  $[x]$  denota la parte entera inferior de  $x$ . Así, el algoritmo puede reescribirse como:

---

```
def udiscreta(n):
    U = random()
    return int(n * U) + 1
```

---

Este algoritmo puede extenderse al caso de generación de una variable aleatoria discreta uniforme con valores enteros en el intervalo  $[m, k]$ , esto es,  $U \sim U[m, k]$ . Notemos que  $X$  toma  $k - m + 1$  valores:

$$m, \quad m+1, \quad m+2, \quad \dots \quad k = m + (k - m).$$

Por lo tanto es suficiente generar una variable uniforme con valores en  $[1, k - m + 1]$  y sumarle  $m - 1$  a cada valor.

---

```
def udiscreta(m, k):
    U = random()
    return int((k - m + 1) * U) + m
```

---

**Generación de una permutación aleatoria de un conjunto de cardinal  $N$** 

Una aplicación de la generación de variables aleatorias con distribución uniforme discreta es el de generar **permutaciones aleatorias** en un conjunto de cardinal  $N$ . El número de permutaciones de un conjunto de  $N$  elementos es  $N!$ , y el objetivo es poder generar permutaciones **equiprobables**, es decir, cada una con probabilidad  $\frac{1}{N!}$  de ocurrencia.

Consideramos un ordenamiento de los elementos de un conjunto  $A$ , de cardinal  $N$ :

$$(a_0, a_1, \dots, a_{N-1})$$

Una primera idea, pero errónea, es intercambiar  $a_0$  con cualquier elemento de  $A$  elegido con distribución uniforme, luego intercambiar  $a_1$  con otro elegido uniformemente en  $A$ , y así siguiendo. Si bien se obtiene una permutación de  $A$ , ocurre que este procedimiento no genera todas las permutaciones con la misma probabilidad. Un algoritmo que ejecute estos pasos tiene  $N^{N-1}$  secuencias diferentes de ejecución, pero

$$\frac{N^{N-1}}{N!}$$

no es un número entero, salvo para  $N = 2$ . Por lo tanto, para  $N > 2$  no es posible que todas las permutaciones se obtengan con la misma probabilidad.

En cambio, si se intercambia  $a_0$  con algún elemento de  $\{a_0, \dots, a_{N-1}\}$  elegido aleatoriamente, luego  $a_1$  con alguno de  $\{a_1, \dots, a_{N-1}\}$  y así siguiendo hasta intercambiar  $a_{N-2}$  con un elemento de  $\{a_{N-2}, a_{N-1}\}$ , entonces el método genera todas las permutaciones con igual probabilidad:

---

```
def permutacion(a): #a=[a[0], a[1], ..., a[N-1]]
    N = len(a)
    for j in range(N-1):
        indice = int((N-j) * random()) + j
        a[j], a[indice] = a[indice], a[j]
    return a
```

---

Notemos que en los sucesivos pasos se generan uniformes en los intervalos de enteros  $[0, N-1]$ ,  $[1, N-1]$ ,  $\dots$ ,  $[N-2, N-1]$ . Si se recorre el arreglo en sentido inverso, comenzando por intercambiar  $a_{N-1}$  en lugar de  $a_0$ , entonces el algoritmo requiere generar uniformes en  $[0, N-1]$ ,  $[0, N-2]$ ,  $\dots$ ,  $[0, 1]$ , que se reducen a calcular una parte entera inferior:

---

```
def permutacion(a): #a=[a[0], a[1], ..., a[N-1]]
    N = len(a)
    for j in range(N-1, 0, -1):
```

---

---

```

indice = int((j+1) * random())
a[j], a[indice] = a[indice], a[j]

```

---

En ciertos casos de muestreo se requiere obtener un subconjunto aleatorio de cierto conjunto de individuos. Es decir, dado un conjunto de  $N$  elementos, obtener un subconjunto de  $r$  elementos, con  $r < N$ , pero elegidos aleatoriamente.

Si el ciclo del algoritmo anterior se ejecuta para  $j = N - 1, N - 2, \dots, N - r$ , los últimos  $r$  elementos del vector permutado forman un subconjunto aleatorio de cardinal  $r$ , y en consecuencia los restantes forman un subconjunto aleatorio de tamaño  $N - r$ . Así, para mayor eficiencia, si  $r < N/2$  conviene ejecutar el algoritmo  $r$  veces y tomar los últimos  $r$  elementos, y de lo contrario conviene ejecutarlo  $N - r$  veces, y tomar los  $r$  primeros.

---

```

## Devuelve un subconjunto aleatorio de A de r elementos
def subcAleatorio(r,A):
    N = len(A)
    for j in range(N-1, N-1-r, -1):
        indice = int((j+1) * random())
        A[j], A[indice] = A[indice], A[j]
    return A[n-r:]

```

---

Un **método alternativo** para obtener permutaciones aleatorias de un conjunto de cardinal  $N$  consiste en generar  $N$  números aleatorios:  $u_0, u_1, u_2, \dots, u_{N-1}$ , y luego ordenarlos, por ejemplo, de menor a mayor:

$$u_{i_0} < u_{i_1} < u_{i_2} < \dots < u_{i_{N-1}}.$$

Así, los índices de los números ya ordenados forman una permutación del conjunto  $\{1, 2, \dots, N\}$ :

$$(i_0, i_1, i_2, \dots, i_{N-1}).$$

Sin embargo este método tiene la desventaja de requerir  $O(N \log(N))$  comparaciones.

### 5.1.2. Cálculo de promedios

Recordemos que el Método de Monte Carlo se basa en dos resultados teóricos fundamentales: la Ley Fuerte de los Grandes Números, y la posibilidad de calcular el valor esperado  $E[g(X)]$  a partir de la función de densidad o de probabilidad de masa, según corresponda, de la variable aleatoria  $X$ .

Supongamos que se quiere calcular un promedio de una gran cantidad de valores:

$$\bar{a} = \frac{1}{N} \sum_{i=1}^N a_i = \frac{a_1 + a_2 + \dots + a_N}{N},$$

donde  $N \gg 1$ , y que por la gran cantidad de términos o por la complejidad de éstos resulta muy complicado calcular la suma. Notemos que si  $X$  es una variable aleatoria uniforme discreta en  $[1, N]$ , y  $g$  es una función tal que  $g(i) = a_i$ , entonces el valor que se desea calcular es justamente  $E[g(X)]$ :

$$\bar{a} = E[g(X)].$$

Luego, por la Ley Fuerte de los grandes números, se tiene que si  $X_1, X_2, \dots, X_n, \dots$  son variables aleatorias independientes, uniformes en  $[1, N]$ , entonces

$$\frac{1}{n}(g(X_1) + g(X_2) + \dots + g(X_n)) \simeq \frac{1}{n}(a_{X_1} + a_{X_2} + \dots + a_{X_n}) = \bar{a}.$$

Así el valor de  $\bar{a}$  se puede estimar como un promedio de  $N$  términos de la sumatoria elegidos al azar:

$$\bar{a} \sim \frac{1}{M} \sum_{j=1}^M a_{i_j}.$$

**Ejemplo 5.2.** Se requiere calcular el promedio

$$S = \sum_{i=1}^{10000} e^{\frac{1}{i}}.$$

Luego tomamos  $g(i) = \exp(1/i)$ , y estimamos  $E[g(X)]$  para  $X \sim U[1, 10000]$ . Notemos que

$$S = 10000 \cdot \frac{1}{10000} \sum_{i=1}^{10000} e^{\frac{1}{i}} = 10000 \cdot E[g(X)].$$

Usando Monte Carlo, se puede estimar el valor de  $\frac{S}{10000}$  con 100 simulaciones de la siguiente forma:

- Generar 100 valores de  $U$ ,  $U = u_i$ ,  $1 \leq i \leq 100$ , con distribución uniforme en  $[1, 10000]$ .
- Calcular para cada uno  $\exp(1/u_i)$ .
- Sumarlos y dividir por 100.

Como estos pasos llevan a una aproximación de  $S/10000$ , la estimación de  $S$  se obtiene multiplicando por 10000.

$$S = \sum_{i=1}^{10000} e^{\frac{1}{i}} \sim 10000 \cdot \frac{1}{100} \sum_{i=1}^{100} e^{\frac{1}{u_i}}.$$

---

```
Suma=0
Nsim=100
for _ in range(Nsim):
    U = int(random() * 10000) + 1
    Suma += exp(1 / U)
Suma = Suma / Nsim * 10000
```

---

### 5.1.3. Generación de una variable aleatoria geométrica

Una variable aleatoria geométrica con probabilidad de éxito  $p$  tiene una probabilidad de masa dada por:

$$p_i = P(X = i) = pq^{i-1}, \quad i \geq 1, \quad q = (1 - p),$$

y la función de distribución acumulada cumple:

$$F_X(j-1) = P(X \leq j-1) = 1 - P(X > j-1) = 1 - q^{j-1}.$$

El método de la transformada inversa asigna entonces el valor  $X = j$  si  $U \in [1 - q^{j-1}, 1 - q^j)$ , es decir:

$$1 - q^{j-1} \leq U < 1 - q^j \quad \text{si y sólo si} \quad q^j < 1 - U \leq q^{j-1}.$$

Dado que  $0 < q < 1$ , las potencias de  $q$  son decrecientes. Por lo tanto la propiedad anterior equivale a encontrar el menor  $j$  tal que  $q^j < 1 - U$ :

$$X = \min\{j : q^j < 1 - U\}.$$

Para determinar  $j$ , aplicamos el logaritmo, y así:

$$X = j \quad \text{si y sólo si} \quad j = \min\{k \mid k \log(q) < \log(1 - U)\}.$$

o equivalentemente y usando que  $\log(q) < 0$ :

$$X = j \quad \text{si y sólo si} \quad j = \min\{k \mid k > \frac{\log(1 - U)}{\log(q)}\} = \left\lfloor \frac{\log(1 - U)}{\log(q)} \right\rfloor + 1$$

Así, el algoritmo para generar valores de una variable aleatoria con distribución geométrica  $X \sim \text{Geom}(p)$  es el siguiente:

---

```
def geometrica(p):
    U=1-random()
    return int(log(U)/log(1-p))+1
```

---

Ahora, si  $U \sim U(0, 1)$ , también lo es  $V = 1 - U$ . Por lo tanto se puede modificar el algoritmo cambiando  $1 - U$  por  $U$ . De todos modos, si el generador de uniformes puede alcanzar el valor 0 entonces  $\log(U)$  no estará definido.

### 5.1.4. Generación de variables Bernoulli

Un método sencillo de generar valores de una Bernoulli  $B(p)$  es:



---

```
def Bernoulli(p):
    U=random()
    if U<p: return 1
    else:    return 0
```

---

Ahora bien, si se quiere obtener una secuencia de valores de  $N$  variables Bernoulli, independientes, puede optimizarse el algoritmo anterior utilizando la generación de una variable geométrica. Notemos que  $X \sim \text{Geom}(p)$  es la variable que mide el número de ensayos independientes de una variable Bernoulli  $B(p)$  hasta obtener un éxito. Entonces, si por ejemplo se genera el valor  $X = 5$ , esto es equivalente a generar 5 valores consecutivos de una variable  $B(p)$ :

0    0    0    0    1.

Así, si se quieren generar  $N$  valores de variables aleatorias  $B(p)$ , independientes, es suficiente generar valores de  $X \sim \text{Geom}(p)$ ,  $x_1, x_2, \dots, x_k$ , hasta que  $x_1 + x_2 + \dots + x_k \geq N$ , y así se obtiene la secuencia de Bernoulli:

$\underbrace{0 \quad 0 \quad \dots \quad 1}_{(x_1-1) \text{ ceros y un } 1} \quad \underbrace{0 \quad 0 \quad \dots \quad 1}_{(x_2-1) \text{ ceros y un } 1} \dots \quad \underbrace{0 \quad 0 \quad \dots \quad 1}_{(x_k-1) \text{ ceros y un } 1}.$

---

```
##devuelve una lista de N Bernoullis B(p)
```

```
def NBernoullis(N,p):
    Bernoullis = np.zeros(N,dtype=int)
    j=geometrica(p)-1
    while j<N:
        Bernoullis[j]=1
        j+= geometrica(p)
    return Bernoullis
```

---

### 5.1.5. Generación de una variable aleatoria Poisson

La función de probabilidad de masa de una variable aleatoria Poisson de razón  $\lambda$  está dada por:

$$p_i = P(X = i) = e^{-\lambda} \frac{\lambda^i}{i!}, \quad i = 0, 1, 2, \dots$$

Notemos que las probabilidades cumplen una relación de recurrencia:

$$p_0 = e^{-\lambda}, \quad p_{i+1} = e^{-\lambda} \frac{\lambda^{i+1}}{(i+1)!} = p_i \frac{\lambda}{i+1}.$$

Así, el algoritmo obtenido por el método de la transformada inversa se puede escribir:

---

```
def Poisson(lamda):
    U = random()
    i = 0; p = exp(-lamda)
    F=p
    while U >= F:
        i += 1
        p *=lamda / i
        F = F + p
    return i
```

---

Una observación con respecto a este algoritmo, es que chequea desde el valor 0 en adelante, pero  $p_0$  no es la probabilidad mayor. Se podría optimizar si el algoritmo recorre primero las probabilidades más grandes. Además, el algoritmo realiza  $n + 1$  comparaciones para generar el valor  $n$ . Dado que el valor esperado de la variable es  $\lambda$ , entonces el número de comparaciones es, en promedio,  $\lambda + 1$ . Así, si  $\lambda \gg 1$  el algoritmo realiza muchas comparaciones.

Una forma de mejorar este algoritmo es comenzar por analizar el valor más probable. El valor máximo de las probabilidades es  $p_{\lfloor \lambda \rfloor}$ , es decir, que los valores cercanos a  $\lambda$  son los más probables. Así, se comienza el algoritmo buscando a partir del valor

$$I = \lfloor \lambda \rfloor,$$

y luego se busca de manera ascendente o descendente según el valor de la variable uniforme  $U$  generada:

---

```
def Poisson(lamda):
    p = np.exp(-lamda);    F=p
    for j in range(1, int(lamda)+1):
        p *= lamda/j
        F += p
    j = int(lamda)
    U = random()
    if U<F:
        while U<F:
            F -= p; p*=j/lamda
            j -=1
        return j+1
    else:
        while U>=F:
            j += 1
```

---

---

```

    p *= lamda/j; F +=p
    return j

```

---

De esta manera, el promedio de búsquedas se reduce a

$$1 + E[|X - \lambda|].$$

En particular, si  $\lambda \gg 1$ , la distribución se aproxima a una normal de media y varianza  $\lambda$ ,  $N(\lambda, \sqrt{\lambda})$ , por lo cual  $\frac{X-\lambda}{\sqrt{\lambda}}$  se aproxima a una normal estándar  $Z \sim N(0, 1)$ .

Por lo tanto, el promedio de búsquedas,  $1 + E[|X - \lambda|]$ , puede estimarse como:

$$\begin{aligned}
 1 + \sqrt{\lambda} E\left[\frac{|X - \lambda|}{\sqrt{\lambda}}\right] &= 1 + \sqrt{\lambda} E[|Z|] \\
 &= 1 + 0.798\sqrt{\lambda}.
 \end{aligned}$$

### 5.1.6. Generación de una variable aleatoria binomial

La generación de una variable aleatoria binomial responde a un caso similar al de una variable Poisson. Si  $X \sim B(n, p)$ , entonces la función de masa de probabilidad es:

$$p_i = P(X = i) = \frac{n!}{i!(n-i)!} p^i (1-p)^{n-i}, \quad i = 0, 1, \dots, n.$$

En este caso, la fórmula recursiva para las probabilidades está dada por:

$$p_0 = (1-p)^n, \quad p_{i+1} = \frac{n-i}{i+1} \frac{p}{1-p} p_i, \quad 0 \leq i < n.$$

Recordamos además que el valor esperado y la varianza están dados por

$$E[X] = np \quad \text{Var}[X] = np(1-p).$$

Si se aplica directamente el método de transformada inversa, el algoritmo resulta:

---

```

def Binomial(n, p):
    i=0
    c= p/(1-p)
    prob=(1-p)**n
    F=prob
    U=random()
    while U >= F:
        prob=c*(n-i)/(i+1)*prob
        F= F+ prob
        i= i+1
    return i

```

---

Al igual que con la generación de v.a. Poisson, el inconveniente de este algoritmo es que al chequear desde 0 hasta generar el valor correspondiente, el número de comparaciones es 1 más que el valor generado. Por lo tanto, el promedio de comparaciones es  $E[X] + 1 = np + 1$ .

Además de la optimización análoga al método de Poisson, una alternativa que podría mejorar el número de comparaciones es si  $p > 1/2$ . En este caso,  $1 - p < \frac{1}{2}$ , y por lo tanto es conveniente generar  $Y \sim B(n, 1 - p)$ , que lleva menor número de comparaciones, y tomar  $X = n - Y$ .

En cuanto a mejorar el algoritmo de manera análoga que Poisson, en este caso el valor más probable corresponde a

$$i = \lfloor np \rfloor,$$

y el promedio de comparaciones, para  $n$  grande resulta del orden de

$$1 + \sqrt{np(1-p)} \approx 0.798.$$

## 5.2. Método de aceptación y rechazo

El **método de aceptación y rechazo** o método de rechazo para generar una variable aleatoria  $X$ , asume la utilización de un método para la generación de otra variable aleatoria  $Y$  que cumpla con las siguientes propiedades:

- Si  $P(X = x_j) > 0$ , entonces  $P(Y = x_j) > 0$ , para todo  $x_j$  en el rango de  $X$ .
- Existe una constante positiva  $c$  tal que:

$$\frac{P(X = x_j)}{P(Y = y_j)} \leq c,$$

para todos los  $x_j$  tal que  $P(X = x_j) > 0$ .

Si denotamos  $p_j = P(X = x_j)$  y  $q_j = P(Y = x_j)$ , entonces de la segunda propiedad vemos que:

$$\sum_{j \geq 1} p_j \leq c \cdot \sum_{j \geq 1} q_j \leq c$$

Como el miembro izquierdo de la desigualdad es 1, se tiene que la constante  $c$  es siempre mayor o igual a 1. Además la igualdad se daría sólo en el caso en que  $X$  e  $Y$  tienen la misma distribución de probabilidad, en cuyo caso ya se tendría un método para generar  $X$ . Asumimos entonces que  $c > 1$ , y por lo tanto  $\frac{1}{c} < 1$ .

El algoritmo propuesto consiste en repetir los siguientes pasos:

```

1 Simular Y
2 U = random()
3 if U < p(Y) / (c * q(Y)) :
4     return Y    ## aceptación: X=Y
5 else:
6     volver a 1 ## rechazo

```

Como puede verse de la descripción del algoritmo, se trata de un ciclo de pasos donde, en caso de un rechazo se cumple otra iteración. Existe en esto una cierta analogía con una variable geométrica, en el sentido que se continúa el ciclo o ejecución de los condicionales (ensayos) hasta que se obtiene un éxito: aceptar el valor de  $Y$ .

En efecto, en cada paso, la probabilidad de generar algún valor de  $X$  es la probabilidad de aceptar el valor de  $Y$  en esa iteración, y esto está dado por:

$$\begin{aligned}
 P(\text{aceptar } Y) &= P\left(\{Y = y_1, U < \frac{p_1}{c q_1}\} \cup \{Y = y_2, U < \frac{p_2}{c q_2}\} \cup \dots\right) \\
 &= P\left(\bigcup_{j \geq 1} \{Y = y_j, U < \frac{p_j}{c q_j}\}\right).
 \end{aligned}$$

Notemos que esta unión es disjunta, y además  $U$  e  $Y$  son independientes. Por lo tanto resulta:

$$P(\text{aceptar } Y) = \sum_{j \geq 1} P(Y = y_j) \cdot P(U \leq \frac{p_j}{c q_j}) = \sum_{j \geq 1} q_j \cdot \frac{p_j}{c q_j} = \frac{1}{c}.$$

Ahora bien, un valor particular  $x_j$  de la variable  $X$  será generado sí y sólo si es generado en alguna iteración:

$$\begin{aligned}
 P(\text{generar } x_j) &= \sum_{k \geq 1} P(\text{generar } x_j \text{ en la iteración } k) \\
 &= \sum_{k \geq 1} P(\text{rechazar } Y \text{ } (k-1) \text{ veces y aceptar } Y = x_j \text{ en la iteración } k) \\
 &= \sum_{k \geq 1} \left(1 - \frac{1}{c}\right)^{k-1} P(Y = x_j, U \leq \frac{p_j}{c q_j}) \\
 &= \sum_{k \geq 1} \left(1 - \frac{1}{c}\right)^{k-1} q_j \frac{p_j}{c q_j} \\
 &= p_j.
 \end{aligned}$$

Por lo tanto, el algoritmo simula una variable aleatoria con la distribución deseada. Además, el número de iteraciones del algoritmo hasta aceptar el valor de  $Y$  es una variable aleatoria geométrica con probabilidad de éxito  $\frac{1}{c}$  y de fracaso  $1 - \frac{1}{c}$ . Por lo tanto, cuanto menor sea  $c$  más eficiente será el algoritmo.

**Ejemplo 5.3.** Sea  $X$  una variable aleatoria con valores en  $\{1, 2, \dots, 10\}$  y probabilidades 0.11, 0.12, 0.09, 0.08, 0.12, 0.10, 0.09, 0.09, 0.10, 0.10. Si se generan valores con el método de la transformada inversa, optimizando de modo que los primeros condicionales tengan mayor probabilidad de ser aceptados, el número esperado de iteraciones (comparaciones) será:

$$(1 + 2) \cdot 0.12 + 3 \cdot 0.11 + (4 + 5 + 6) \cdot 0.10 + (7 + 8) \cdot 0.09 + 9 \cdot 0.17 = 5.07.$$

Por otro lado, si se genera esta variable rechazando con una variable aleatoria  $Y \sim U[1, 10]$ , tenemos que  $P(Y = j) = 0.1$ , y por lo tanto

$$P(X = j) \leq 1.2 \cdot P(Y = j), \quad 1 \leq j \leq 10.$$

Luego el valor esperado del número de iteraciones hasta generar un valor de  $X$  es igual al valor esperado de una variable aleatoria geométrica con  $p = \frac{1}{1.2}$ , que es  $c = 1.2$ . Es decir, que requiere la generación de una variable uniforme y una comparación por cada ciclo.

### 5.3. Método de composición

El método de composición permite generar una variable aleatoria  $X$  con función de probabilidad de masa dada por:

$$P(X = j) = \alpha p_j + (1 - \alpha) q_j \quad j = 0, 1, \dots,$$

donde  $\alpha$  es algún número entre 0 y 1.

Entonces, si se tienen métodos eficientes para generar valores de dos variables aleatorias  $X_1$  y  $X_2$ , con funciones de probabilidad de masa

$$P(X_1 = x_j) = p_j, \quad P(X_2 = x_j) = q_j, \quad j = 1, \dots,$$

entonces estos métodos pueden ser utilizados para generar valores de  $X$ :

$$X = \begin{cases} X_1 & \text{con probabilidad } \alpha \\ X_2 & \text{con probabilidad } 1 - \alpha \end{cases}$$

El algoritmo sería como el que sigue:

---

```

U=random()
if U<alfa:
    simular X1
    return X1
else:
    simular X2
    return X2

```

---

Notemos que:

$$\begin{aligned} P(\text{generar } x_j) &= P(U < \alpha, X_1 = x_j) + P(\alpha \leq U < 1, X_2 = x_j) \\ &= P(U < \alpha) P(X_1 = x_j) + P(\alpha \leq U < 1) P(X_2 = x_j) \\ &= \alpha p_j + (1 - \alpha) q_j. \end{aligned}$$

Así la probabilidad de generar  $X = x_j$  es la probabilidad deseada.

**Ejemplo 5.4.** Si  $X$  es la variable aleatoria que toma los valores del 1 al 5 con probabilidad 0.05, y los valores del 6 al 10 con probabilidad 0.15, entonces  $X$  toma algún valor entre 1 y 5 con probabilidad 0.25, y un valor entre 6 y 10 con probabilidad 0.75. Por otro lado, los valores del 1 al 5 son equiprobables y los del 6 al 10 también. Luego se pueden elegir  $X_1$  y  $X_2$  uniformes discretas en  $[1, 5]$  y  $[6, 10]$  respectivamente, y generar  $X$  con el siguiente algoritmo:

---

```
U=random()
V=random()
if U<0.75:
    return int(5*V)+6
else:
    return int(5*V)+1
```

---

También se pueden considerar las variables aleatorias  $Y_1 \sim U[1, 10]$  e  $Y_2 \sim U[6, 10]$ , de modo que los valores de 1 a 5 sean generados con  $Y_1$  y los restantes puedan ser generados con  $Y_1$  o con  $Y_2$ . Esto es:

$$P(Y_1 = j) = 0.1, \quad 1 \leq j \leq 10, \quad P(Y_2 = j) = 0.2, \quad 6 \leq j \leq 10.$$

Dado que  $X$  toma algún valor entre 1 y 5 con probabilidad 0.25, y estos son la mitad de los valores que toma  $Y_1$ , se da una ponderación  $\alpha = 0.5$  a  $Y_1$ , y la misma ponderación a  $Y_2$ . Así, en este caso el algoritmo es el siguiente:

---

```
U=random()
V=random()
If U<0.5:
    return int(10*V)+1
else:
    return int(5*V)+6
```

---

En general, si se tienen  $n$  variables aleatorias con funciones de distribución acumulada  $F_1, F_2, \dots, F_n$ , y  $\alpha_1, \alpha_2, \dots, \alpha_n$  son números positivos tales que

$$\alpha_1 + \alpha_2 + \dots + \alpha_n = 1,$$

entonces la función de distribución acumulada dada por

$$F(x) = \alpha_1 F_1(x) + \alpha_2 F_2(x) + \cdots + \alpha_n F_n(x),$$

se llama una **mezcla** o **composición** de las funciones de distribución  $F_1, F_2, \dots, F_n$ .

Una variable aleatoria  $X$  con función de distribución  $F$  puede generarse a través de la simulación de una variable discreta  $I$  que toma valores en  $\{1, 2, \dots, n\}$  con  $P(I = j) = \alpha_j$ , y una segunda simulación de una variable con distribución  $F_j$ , si  $I = j$ . Esta forma de generar  $X$  se llama **método de composición**.

## 5.4. Métodos alternativos

### 5.4.1. El método del alias

Una aplicación del método de composición es el llamado **método del alias**. Este método sirve para generar variables aleatorias que toman un número finito de valores, digamos,  $1, 2, \dots, n$ .

El método requiere construir en primer lugar los llamados **alias**, pero una vez completada esta etapa la simulación en sí es muy simple. La distribución de la variable  $X$ ,  $F_X$ , se describe como una composición equiprobable de  $n - 1$  variables aleatorias:

$$F_X(x) = \frac{1}{n-1} F_1(x) + \frac{1}{n-1} F_2(x) + \cdots + \frac{1}{n-1} F_{n-1}(x),$$

y  $F_j(x)$  es la distribución de una variable  $X_j$  que toma a lo sumo dos valores posibles.

Para definir esta composición o mezcla, se utiliza el siguiente resultado:

**Proposición 5.1.** Sea  $P(X = j) = p_j$ ,  $1 \leq j \leq n$  una función de probabilidad de masa, con  $n > 1$ . Entonces:

- a) Existe  $j$ ,  $1 \leq j \leq n$ , tal que  $p_j < \frac{1}{n-1}$ .
- b) Dado  $j$  como en a), existe  $i \neq j$  tal que  $p_i + p_j \geq \frac{1}{n-1}$ .

La demostración es sencilla. Para ver a), notemos que si no fuera cierto entonces la suma de las probabilidades cumpliría

$$\sum_{j=1}^n p_j \geq n \cdot \frac{1}{n-1} > 1,$$

lo cual es absurdo.

Por otro lado, dado  $j$  como en a), debe existir  $i$  que cumpla b). De lo contrario, se tendría que:

$$1 - p_j = \sum_{i \neq j} p_i < (n-1) \left( \frac{1}{n-1} - p_j \right) = 1 - (n-1)p_j.$$



Esto es,  $p_j > (n-1)p_j$ , lo cual sólo es válido si  $n = 1$ .

El procedimiento es como sigue. En primer lugar, notemos que si se multiplican todas las probabilidades por  $n-1$ , entonces su suma es igual a  $n-1$ :

$$(n-1)p_1, \quad (n-1)p_2, \quad \dots, \quad (n-1)p_n. \quad (5.1)$$

La idea es distribuir estos  $n-1$  valores dados en (5.1) como probabilidades de masa de  $n-1$  variables aleatorias, de modo que estas variables tomen a lo sumo dos valores distintos. Por ejemplo, si se tuviera una variable aleatoria  $X$  que toma valores en  $\{1, 2, 3\}$  con probabilidades de masa:

$$p_1 = 0.3, \quad p_2 = 0.6, \quad p_3 = 0.1,$$

al mutiplicar por 2 tenemos los valores:

$$2p_1 = 0.6, \quad 2p_2 = 1.2, \quad 2p_3 = 0.2.$$

El objetivo es descomponer la suma de estos tres valores ( $= 2$ ) como la suma de las probabilidades de dos variables aleatorias  $X_1$  y  $X_2$ . El valor más pequeño es 0.2 que corresponde al valor 3. Entonces consideramos una variable  $X_1$  que tome el valor 3 con probabilidad 0.2. Como debe tomar dos valores, el segundo valor debe tener probabilidad 0.8.

Dado que  $2p_2 = 1.2 = 0.8 + 0.4$ , asignamos a  $X_1$  el valor 2 con probabilidad 0.8. Así formamos una primer variable aleatoria  $X_1$  que tome los valores 3 y 2 con probabilidades 0.2 y 0.8, respectivamente.

Ahora, como  $1.2 = 0.8 + 0.4$ , entonces la segunda variable a definir tomará los valores 2 y 1 con probabilidades 0.4 y 0.6:

$$X_1 = \begin{cases} 2 & p = 0.8 \\ 3 & q = 0.2 \end{cases} \quad X_2 = \begin{cases} 1 & p = 0.6 \\ 2 & q = 0.4 \end{cases}$$

y ahora, para cada  $x = 1, 2, 3$  se cumple que:

$$P(X = x) = \frac{1}{2} P(X_1 = x) + \frac{1}{2} P(X_2 = x).$$

En un caso general, se eligen  $j$  e  $i$  como en la Proposición 5.1, y se define

$$X_1 = \begin{cases} j & \text{con probabilidad } (n-1)p_j \\ i & \text{con probabilidad } 1 - (n-1)p_j \end{cases}.$$

Notemos que  $X_1$  toma todo el peso del valor  $j$ , y parte del peso del valor  $i$ . Digamos que de la lista de valores en (5.1) se han utilizado  $p_j$  y una "parte" de  $p_i$ , de modo que suman 1. Si se restan estos dos valores en (5.1), la suma total es igual a  $n-2$ .

Es decir, si dividimos por  $n - 2$  se tendría nuevamente una variable aleatoria  $\tilde{X}$  con valores en  $\{1, 2, \dots, n\} - \{j\}$ , que tiene probabilidades

$$P(\tilde{X} = k) = \frac{1}{n-2} (n-1) p_k, \quad k \neq j, i,$$

y  $P(\tilde{X} = i)$  es tal que la suma de las probabilidades es 1.

Ahora se eligen nuevos índices  $j$  e  $i$  con las propiedades dadas en a) y b) de la Proposición 5.1, respectivamente, y se construye una variable  $X_2$ , cambiando  $n$  por  $n - 1$ . El procedimiento sigue hasta que sólo quedan a lo sumo dos valores por generar.

Notemos que en cada paso, la variable  $X_k$  definida toma todo el peso de su correspondiente valor  $j$ , por lo cual este valor ya no será generado por las siguientes variables  $X_k$ . En consecuencia, el algoritmo de construcción del alias tiene  $n - 1$  pasos.

Ilustramos estos pasos con un ejemplo:

**Ejemplo 5.5.** Por ejemplo, si  $X$  es la v. a. que toma valores en  $\{1, 2, 3, 4\}$  con

$$p_1 = \frac{7}{16}, \quad p_2 = \frac{1}{4}, \quad p_3 = \frac{1}{8}, \quad p_4 = \frac{3}{16}.$$

Multiplicando estas probabilidades por  $n - 1 = 3$ , obtenemos los siguientes valores tabulados en la Tabla 5.1:

Pasos	1	2	3	4	
$p_j \times (3)$	$\frac{21}{16}$	$\frac{3}{4}$	$\frac{3}{8}$	$\frac{9}{16}$	Suma=3

Cuadro 5.1: Método del alias - Paso 1

La Proposición 5.1 nos dice que alguno de los valores de la tabla es menor que 1, y que para este valor hay otro cuya suma excede a 1. En general, se sugiere tomar el menor y mayor valor de la tabla respectivamente. En este caso:  $j = 3$  e  $i = 1$ .

Consideramos entonces la variable aleatoria:

$$X_1 = \begin{cases} 3 & \text{con probabilidad } 3 \cdot p_3 = \frac{3}{8} \\ 1 & \text{con probabilidad } 1 - \frac{3}{8} = \frac{5}{8}. \end{cases}$$

Así, restando las probabilidades que toma  $X_1$  para los valores 3 y 1, la tabla resulta como en la Tabla 5.2:

$j$	1	2	3	4	
$p_j \times 3$	$\frac{21}{16}$	$\frac{3}{4}$	$\frac{3}{8}$	$\frac{9}{16}$	Suma=2
	$\frac{11}{16}$	$\frac{3}{4}$		$\frac{9}{16}$	

Cuadro 5.2: Método del alias - Paso 2

Notemos que esta segunda fila suma 2, y al menos un elemento es menor que 1 y la suma de este con algún otro elemento supera a 1. Podemos elegir en este caso  $j = 4$  e  $i = 2$ , y definir la variable:

$$X_2 = \begin{cases} 4 & \text{con probabilidad } \frac{9}{16} \\ 2 & \text{con probabilidad } 1 - \frac{9}{16} = \frac{7}{16}. \end{cases}$$

Repitiendo el paso anterior, la tabla resulta como en el Cuadro 5.3:

$j$	1	2	3	4	
$p_j \times 3$	$\frac{21}{16}$	$\frac{3}{4}$	$\frac{3}{8}$	$\frac{9}{16}$	
	$\frac{11}{16}$	$\frac{3}{4}$		$\frac{9}{16}$	
	$\frac{11}{16}$	$\frac{5}{16}$			Suma=1

Cuadro 5.3: Método del alias - Paso 3

y en este último paso directamente definimos

$$X_3 = \begin{cases} 1 & \text{con probabilidad } \frac{11}{16} \\ 2 & \text{con probabilidad } \frac{5}{16}. \end{cases}$$

De esta forma, la distribución  $F$  de la variable aleatoria original  $X$  se puede escribir como:

$$F_X(x) = \frac{1}{3} F_{X_1}(x) + \frac{1}{3} F_{X_2}(x) + \frac{1}{3} F_{X_3}(x),$$

y el algoritmo por el método del alias para simular valores de  $X$  será como el siguiente:

---

```
def aliasX():
    I=int (random()*3)
    V=random()
    if I==0:
        if V<5/8:    return 1
        else:        return 3
    elif I==1:
        if V<9/16:   return 4
        else:         return 2
    else: ##I==2
        if V<11/16:  return 1
        else:         return 2
```

---

**Ejercicio 5.1.** Comprobar que el algoritmo anterior genera los valores del 1 al 4 con las probabilidades deseadas.

El nombre de **alias** proviene del hecho que es posible definir las variables  $X_k$  de modo que  $P(X_k = k)$  sea positiva, para  $1 \leq k < n$ . En ese caso,  $X_k$  toma el valor  $k$  y posiblemente otro valor que se denomina su "alias".

También puede optimizarse este algoritmo generando una única variable uniforme  $U \sim U(0, 1)$ , y tomar  $I = \lfloor (n-1)U \rfloor$ , y  $V = (n-1)U - I$ .

### 5.4.2. Método de la urna

Otro método simple, pero quizás menos eficiente en cuanto al uso de memoria, es el **método de la urna**. Dada una variable aleatoria  $X$ , que toma un número finito de valores, digamos  $\{1, 2, \dots, n\}$ , llamamos  $p_j = P(X = j)$ . El método consiste en considerar un valor  $k \in \mathbb{N}$  tal que  $k p_j$  sea entero, para todo  $j$ ,  $1 \leq j \leq n$ .

Ahora se considera un arreglo  $A$  de  $k$  posiciones, y se almacena cada valor  $i$  en  $k p_i$  posiciones del arreglo.

El algoritmo simplemente selecciona una posición al azar del arreglo y devuelve el valor en dicha posición.

---

```
def urnaX():
    I=int(random()*k)
    return A[I]
```

---

**Ejemplo 5.6.** Si  $X$  toma los valores  $\{1, 2, 3\}$  con probabilidades

$$p_1 = 0.24, \quad p_2 = 0.46, \quad p_3 = 0.30,$$

se puede tomar  $k = 100$ . Así, se define un arreglo  $A$  con 100 posiciones, en las cuales se almacena el 1 en 24 posiciones, el 2 en 46 posiciones y el 3 en 30 posiciones.

Una mejora de este método, en cuanto al lugar de almacenamiento, es considerar las posiciones de los décimos, centésimos, milésimos, etc., por separado.

Así, en el Ejemplo 5.6, los décimos en las probabilidades están dados por 2, 4 y 3, y los centésimos están dados por 4, 6 y 0.

Luego se consideran dos arreglos:

1.  $A_1$ : de  $2 + 4 + 3 = 9$  posiciones, con 2 posiciones con el valor 1, 4 posiciones con valor 4 y 3 posiciones con el valor 3.
2.  $A_2$ : de  $4 + 6 + 0 = 10$  posiciones, con 4 posiciones con el valor 1, 6 con el valor 2 y ninguna con el valor 3.

El arreglo  $A_1$  se le da peso  $\frac{90}{100} = 0.9$ , y al arreglo  $A_2$  se le da un peso de  $\frac{10}{100} = 0.10$ , y el algoritmo es como sigue:

---

```
def urnaXmejorada():  
    U=random()  
    if U<0.9:  
        I=int(random()*9)  
        return A1[I]  
    else:  
        I=int(random()*10)  
        return A2[I]
```

---